

UNIVERSIDAD DE ANTIOQUIA

Facultad de Ingeniería

INFORME PROYECTO

Clasificación de Tumores Cerebrales en MRI usando Deep Learning

Asignatura: Deep Learning

Docente: Raúl Ramos Pollán

Fecha: 6 de julio de 2025

Autores

Andrés Arroyave Carmona

andres.arroyavec1@udea.edu.co

<https://github.com/EndymionK>

Andrés Felipe Calvo Ariza

andres.calvoa@udea.edu.co

<https://github.com/andres-calvo>

Jair Santiago Leal Miranda

jair.leal@udea.edu.co

<https://github.com/Jairleal14>

Índice

1	Introducción	2
2	Estructura de la entrega	2
3	Descripción de los notebooks entregados	3
4	Descripción de la solución y decisiones tomadas	3
5	Resultados y análisis	4
6	Obtención y preparación de los datos	4
7	Modelos entrenados	5
8	Video de presentación	5
9	Conclusiones	5

INFORME PROYECTO

Clasificación de Tumores Cerebrales en MRI usando Deep Learning

Asignatura: Deep Learning **Docente:** Raúl Ramos Pollán **Universidad:** Universidad de Antioquia **Fecha:** 6 de julio de 2025

1. Introducción

La detección y clasificación automática de tumores cerebrales en imágenes de resonancia magnética (MRI) representa un desafío fundamental en la intersección entre la ingeniería y la medicina. El diagnóstico temprano y preciso de tumores cerebrales puede marcar la diferencia en el pronóstico y tratamiento de los pacientes, pero la interpretación de imágenes médicas requiere experiencia y tiempo, recursos que no siempre están disponibles en todos los contextos hospitalarios.

Por ello, el desarrollo de herramientas automáticas basadas en inteligencia artificial puede ser de gran ayuda para los profesionales de la salud, permitiendo acelerar el proceso diagnóstico y reducir la carga de trabajo de los especialistas.

En este proyecto, como estudiantes de Ingeniería de Sistemas, nos propusimos diseñar e implementar un sistema de clasificación de tumores cerebrales en imágenes MRI utilizando técnicas de deep learning, específicamente redes neuronales convolucionales (CNN). El objetivo principal fue construir un pipeline robusto, reproducible y fácilmente ejecutable en Google Colab, capaz de distinguir entre tres tipos de tumores: glioma, meningioma y tumor genérico.

2. Estructura de la entrega

La entrega está compuesta por varios elementos cuidadosamente organizados para facilitar la comprensión y la reproducibilidad del trabajo realizado. En la carpeta `notebooks/` se encuentran todos los cuadernos de Jupyter que documentan cada etapa del proceso, desde el preprocesado de los datos hasta la evaluación final de los modelos. Los modelos entrenados se almacenan en la carpeta `models/`, permitiendo su reutilización o análisis posterior. Además, se incluye este informe ejecutivo, que detalla las decisiones tomadas, los experimentos realizados y los resultados obtenidos. Finalmente, se ha preparado un video de presentación donde se explica el flujo de trabajo, se muestran los notebooks en ejecución y se discuten los principales hallazgos.

Estructura de carpetas:

`notebooks/`

```
01_preprocesado.ipynb
02.1_busqueda_hiperparametros.ipynb
02.2a_modelado_cnn.ipynb
02.2b_modelado_transfer_learning.ipynb
03_evaluacion.ipynb
04_proceso_colab.ipynb
models/
data/
```

3. Descripción de los notebooks entregados

`01_preprocesado.ipynb`: Se realiza el preprocesamiento de las imágenes (escalado, normalización, redimensionamiento y organización por clase). Se visualizan ejemplos para verificar calidad.

`02.1_busqueda_hiperparametros.ipynb`: Búsqueda sistemática de hiperparámetros mediante grid search, explorando filtros, unidades densas, tasas de dropout y tasas de aprendizaje.

`02.2a_modelado_cnn.ipynb`: Entrenamiento y evaluación de una CNN propia, ajustando la arquitectura con los mejores hiperparámetros obtenidos.

`02.2b_modelado_transfer_learning.ipynb`: Transfer learning con VGG16 preentrenada sobre ImageNet. Se añade una cabeza densa personalizada y se experimenta con fine-tuning.

`03_evaluacion.ipynb`: Evaluación de modelos con métricas como accuracy, precision, recall, F1-score y matrices de confusión. Se analizan curvas de aprendizaje y errores frecuentes.

`04_proceso_colab.ipynb`: Adaptación completa del pipeline para ejecución en Google Colab, validando compatibilidad y reproducibilidad.

4. Descripción de la solución y decisiones tomadas

4.1 Preprocesado

- Conversión a escala de grises para reducir dimensionalidad.
- Redimensionamiento a 224x224 píxeles por compatibilidad con VGG16.
- Normalización al rango $[0, 1]$ para mejorar la convergencia del modelo.
- Organización del dataset por carpetas por clase para facilitar su uso.

4.2 Arquitecturas y experimentos

Iteración 1 – CNN desde cero: Se diseñó una arquitectura CNN propia con tres bloques convolucionales. Se realizó una búsqueda de hiperparámetros para establecer una línea base.

Iteración 2 – Transfer Learning (VGG16): Se implementó VGG16 preentrenada. Inicialmente con capas congeladas, luego con fine-tuning de las últimas capas para mejorar la generalización.

Iteración 3 – Pruebas en Colab: Se portó todo el pipeline a Google Colab, aprovechando GPU y asegurando resultados reproducibles.

5. Resultados y análisis

VGG16 (transfer learning):

- Accuracy en validación: $> 91\%$
- Accuracy en test: $\sim 89\%$

CNN propia:

- Accuracy en validación: $\sim 88\%$

La principal confusión se dio entre "glioma y "tumor genérico", posiblemente por similitudes visuales. Se aplicaron técnicas de data augmentation (rotaciones, flips, zoom) para mejorar la robustez.

Se ajustaron hiperparámetros, tasa de aprendizaje, tamaño de batch y capas entrenables en VGG16 para encontrar el equilibrio entre rendimiento y sobreajuste.

6. Obtención y preparación de los datos

Fuente:

- Kaggle: <https://www.kaggle.com/datasets/orvile/brain-cancer-mri-dataset>
- Mendeley Data: <https://data.mendeley.com/datasets/mk56jw9rns/1>

Preparación:

1. Descarga del dataset.
2. Extracción en `data/original/`.
3. Ejecución de `01_preprocesado.ipynb` para preparar las imágenes.

4. Verificación de estructura y balance de clases.

7. Modelos entrenados

Los modelos se almacenan en la carpeta `models/` y están nombrados con fecha y accuracy para facilitar su identificación. Se pueden cargar desde los notebooks para reproducir o continuar los experimentos.

8. Video de presentación

Se ha preparado un video explicando el flujo de trabajo, los notebooks, y los resultados obtenidos.

Enlace al video de YouTube: https://www.youtube.com/watch?v=9XnxZyjYLic&ab_channel=ANDRESFELIPECALVOARIZA

9. Conclusiones

Este proyecto permitió comprobar el potencial del deep learning y el transfer learning en la clasificación médica. El preprocesamiento adecuado, la exploración de arquitecturas y el ajuste de hiperparámetros fueron claves para alcanzar buenos resultados. El sistema resultante es reproducible y portable, lo que lo hace útil para futuros desarrollos o investigación clínica.